МИНОБРНАУКИ РОССИИ
САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ
ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
«ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА)
Кафедра Математического обеспечния и применения ЭВМ

ОТЧЕТ

по лабораторной работе №5

по дисциплине «Искуссенные нейронные сети»

Тема: «Распознавание объектов на фотографиях»

Студент гр. 7382 _____ Находько А.Ю.

Преподаватель _____ Жукова Н.В.

Санкт-Петербург

2020

Цель работы.

Распознавание объектов на фотографиях (Object Recognition in Photographs)

CIFAR-10 (классификация небольших изображений по десяти классам: самолет, автомобиль, птица, кошка, олень, собака, лягушка, лошадь, корабль и грузовик).

Задачи работы.

•Ознакомиться со сверточными нейронными сетями

•Изучить построение модели в Keras в функциональном виде

•Изучить работу слоя разреживания (Dropout)

Требования работы.

1. Построить и обучить сверточную нейронную сеть
2. Исследовать работу сеть без слоя Dropout
3. Исследовать работу сети при разных размерах ядра свертки

Основные теоретические положения.

Искусственные нейронные сети - совокупность моделей, которые представляют собой сеть элементов - искусственных нейронов, связанных между собой синаптическими соединениями.

Нейронные сети используются как среда, в которой осуществляется адаптивная настройка параметров дискриминантных функций. Настройка происходит при последовательном предъявлении обучающих выборок образов из разных классов. Обучение - такой выбор параметров нейронной сети, при котором сеть лучше всего справляется с поставленной проблемой.

Нейрон — элемент, преобразующий входной сигнал по функции.

Сумматор — элемент, осуществляющий суммирование сигналов поступающих на его вход.

Синапс — элемент, осуществляющий линейную передачу сигнала.

Экспериментальные результаты.

В ходе выполнения лабораторной работы была создана и обучена модель нейронной сети, код которой представлен в приложении А.

Эксперимент 1. Была построена и обучена нейронная сеть с параметрами: batch_size = 256, num_epochs = 15 и размерностью свёртки 3x3.

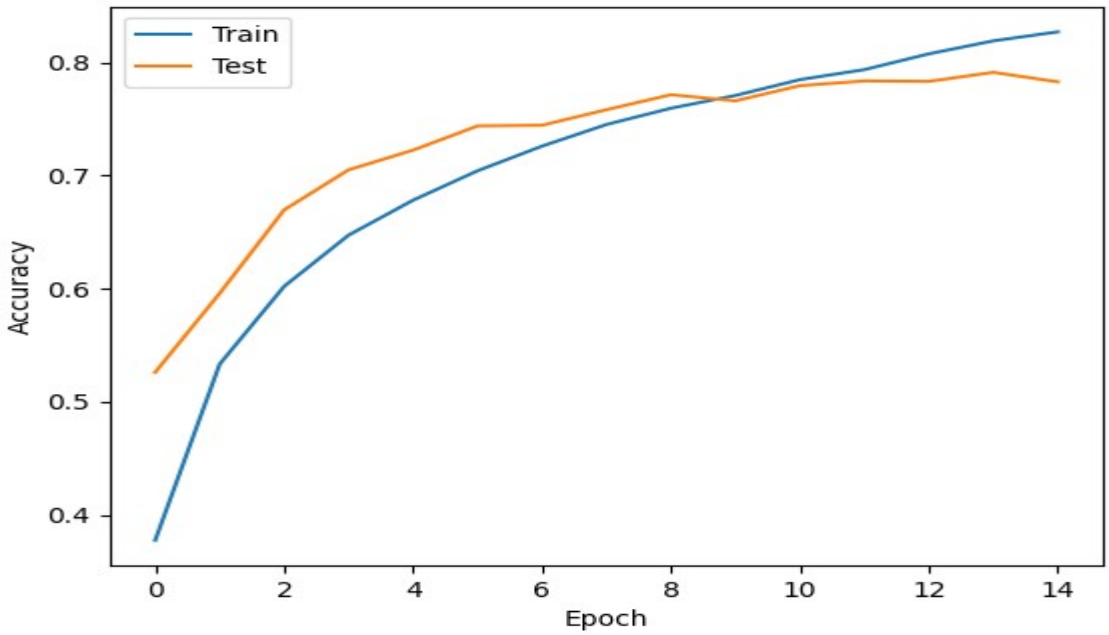

Рисунок 1 — График точности для начальной модели

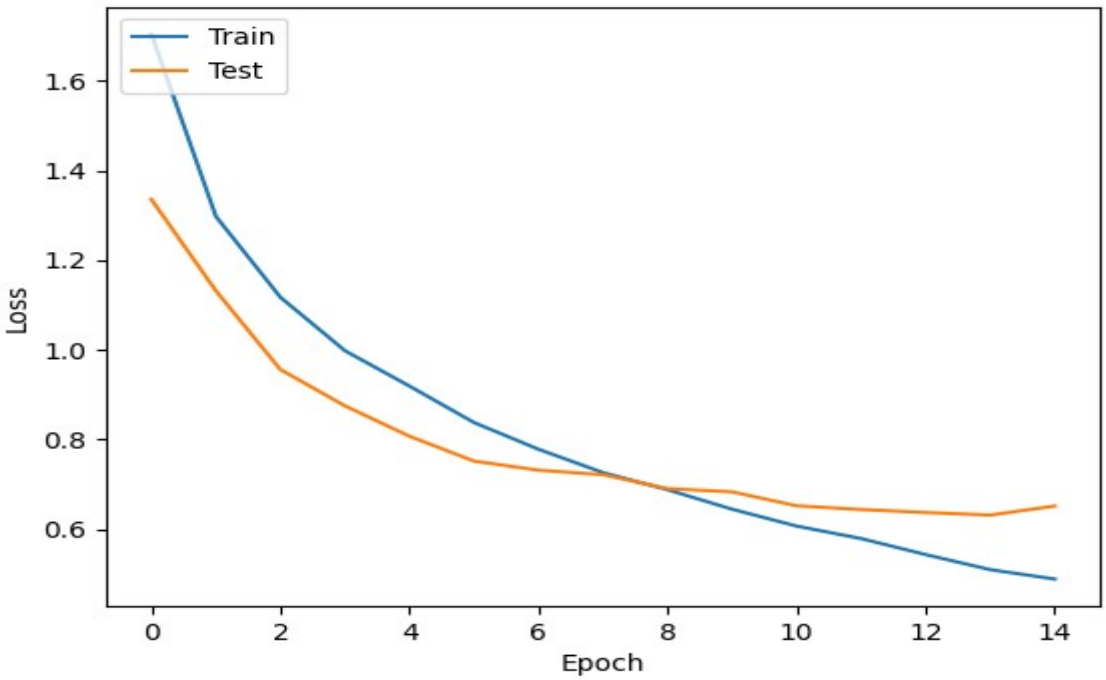

Рисунок 2 — График потерь для начальной модели

Полученный результат точности 78%.

Эксперимент 2. Запустим обучение сети без использования dropout слоёв.

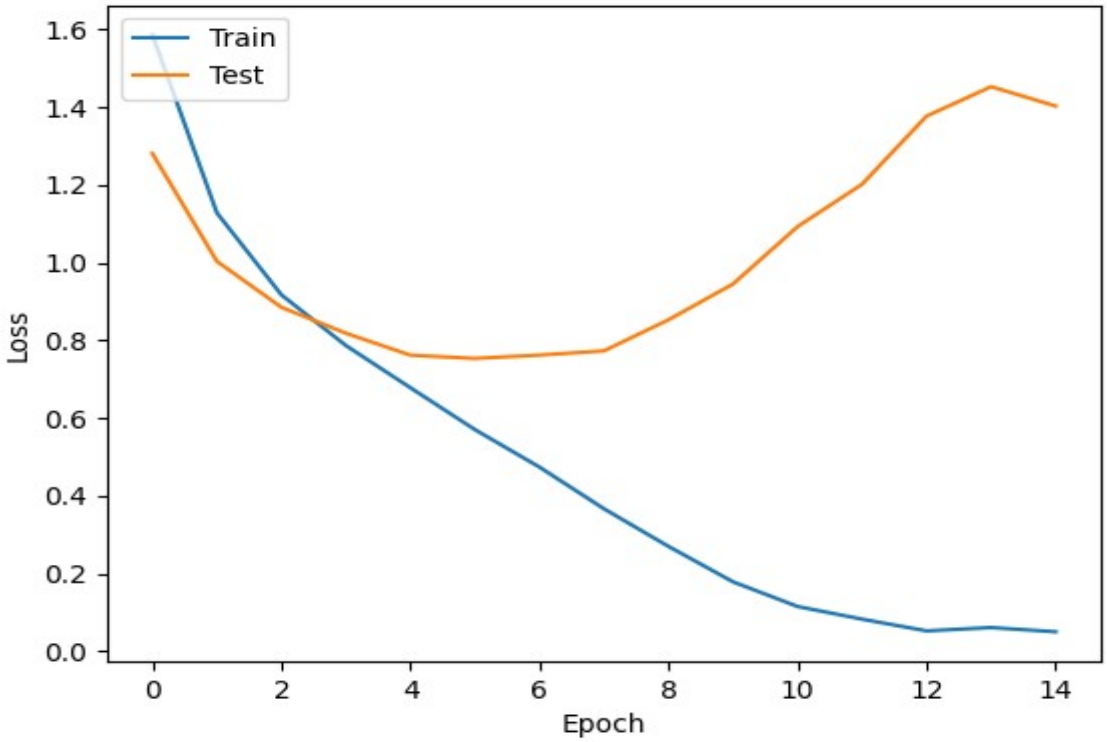

Рисунок 3 — График потерь для модели без dropout слоёв

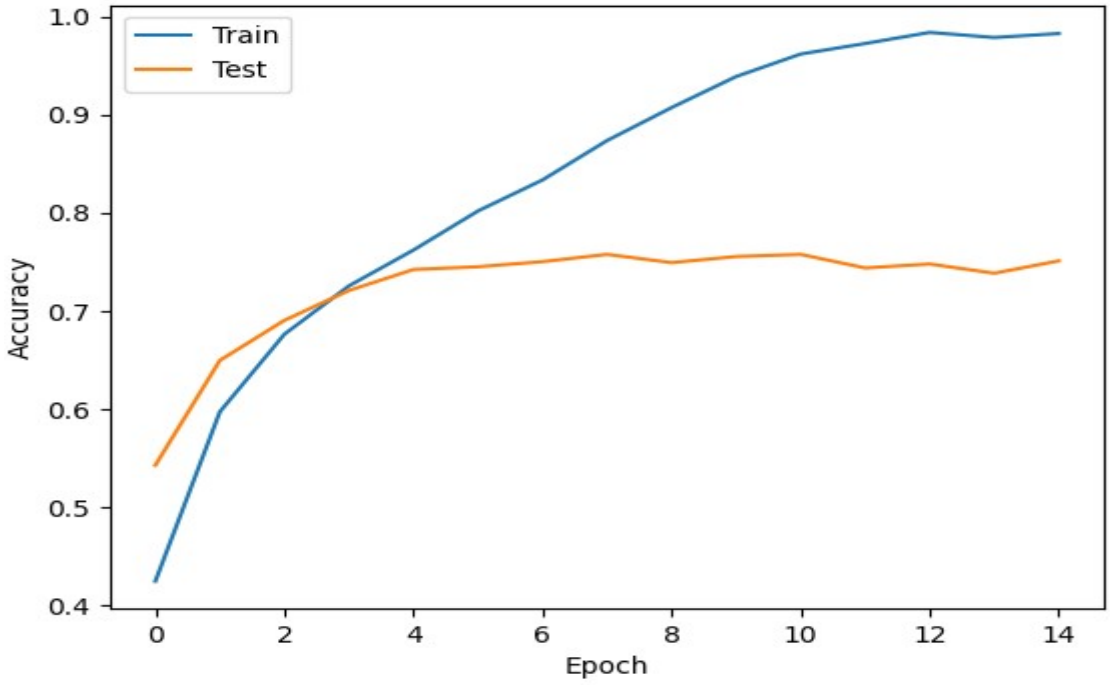

Рисунок 4 — График потерь для модели без dropout слоёв

Заметим, что произошло переобучение уже на 3 эпохе.

Эксперимент 3. Попробуем запустить обучение сети изменяя размерность ядра 3x3, 5x5.

Графики точности и потерь для НС размерностью ядра 3x3:

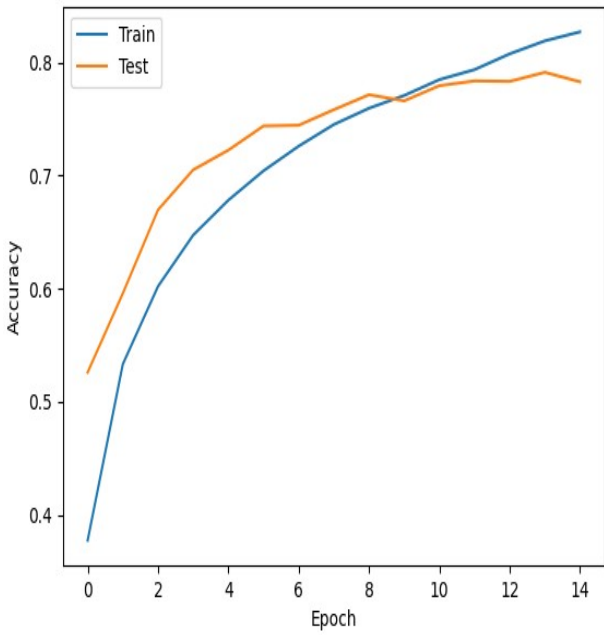

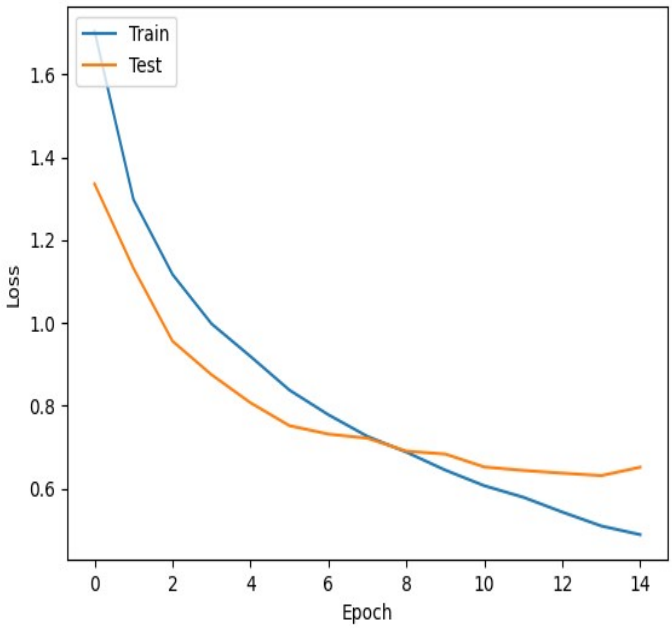

Графики точности и потерь для НС размерностью ядра 5x5:

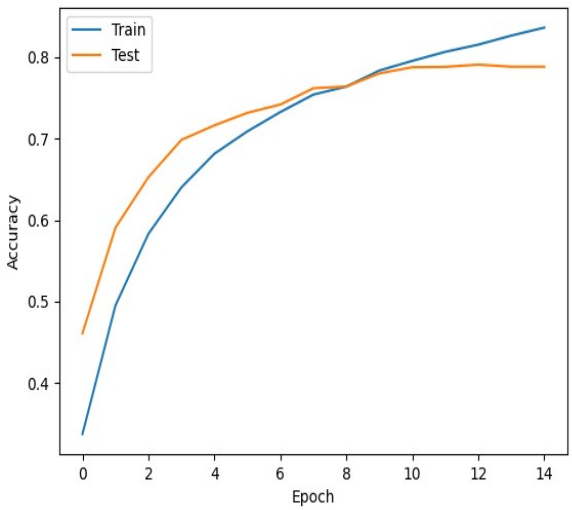

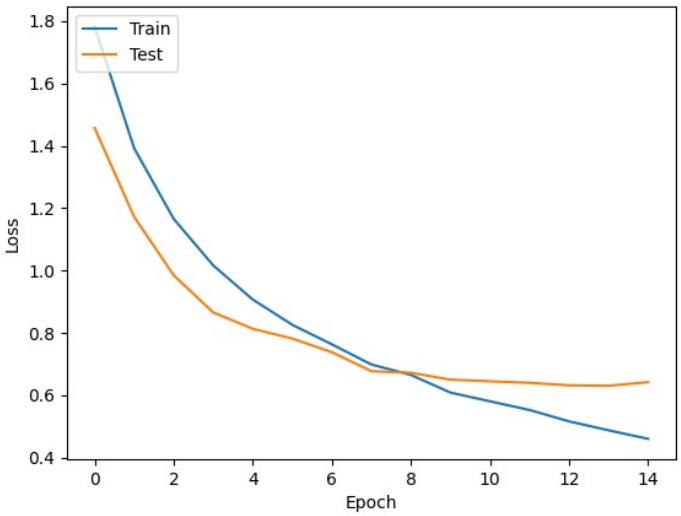

Заметим, что увеличение размера ядра свёртки приводит к уменьшению точности и ухудшению результата.

Выводы.

В ходе выполнения лабораторной работы была построена и обучена свёрточная нейронная сеть, также исследована работа без слоя Dropout и было проведено исследование работы сети при разных размерах ядра свёртки. Рассмотено построение модели в Keras в функциональном виде.

ПРИЛОЖЕНИЕ А

ИСХОДНЫЙ КОД

```
from keras.datasets import cifar10
from keras.models import Model
from keras.layers import Input, Convolution2D, MaxPooling2D, Dense,
Dropout, Flatten
from keras.utils import np_utils
import numpy as np
import matplotlib.pyplot as plt

batch_size = 256 # in each iteration, we consider 256 training examples
at once
num_epochs = 15 # we iterate 15 times over the entire training set
kernel_size = 3 # we will use 3x3 kernels throughout
pool_size = 2 # we will use 2x2 pooling throughout
conv_depth_1 = 32 # we will initially have 32 kernels per conv. layer...
conv_depth_2 = 64 # ...switching to 64 after the first pooling layer
drop_prob_1 = 0.25 # dropout after pooling with probability 0.25
drop_prob_2 = 0.5 # dropout in the dense layer with probability 0.5
hidden_size = 512 # the dense layer will have 512 neurons



(X_train, y_train), (X_test, y_test) = cifar10.load_data() # fetch
CIFAR-10 data

num_train, depth, height, width = X_train.shape # there are 50000
training examples in CIFAR-10
num_test = X_test.shape[0] # there are 10000 test examples in CIFAR-10
num_classes = np.unique(y_train).shape[0] # there are 10 image classes

X_train = X_train.astype('float32')
X_test = X_test.astype('float32')
X_train /= np.max(X_train) # Normalise data to [0, 1] range
X_test /= np.max(X_train) # Normalise data to [0, 1] range

Y_train = np_utils.to_categorical(y_train, num_classes) # One-hot encode
```

```
the labels
Y_test = np_utils.to_categorical(y_test, num_classes) # One-hot encode
the labels

inp = Input(shape=(depth, height, width)) # N.B. depth goes first in
Keras

# Conv [32] -> Conv [32] -> Pool (with dropout on the pooling layer)
conv_1 = Convolution2D(conv_depth_1, kernel_size, kernel_size,
border_mode='same', activation='relu')(inp)
conv_2 = Convolution2D(conv_depth_1, kernel_size, kernel_size,
border_mode='same', activation='relu')(conv_1)
pool_1 = MaxPooling2D(pool_size=(pool_size, pool_size))(conv_2)
drop_1 = Dropout(drop_prob_1)(pool_1)

# Conv [64] -> Conv [64] -> Pool (with dropout on the pooling layer)
conv_3 = Convolution2D(conv_depth_2, kernel_size, kernel_size,
border_mode='same', activation='relu')(drop_1)
conv_4 = Convolution2D(conv_depth_2, kernel_size, kernel_size,
border_mode='same', activation='relu')(conv_3)
pool_2 = MaxPooling2D(pool_size=(pool_size, pool_size))(conv_4)
drop_2 = Dropout(drop_prob_1)(pool_2)

# Now flatten to 1D, apply Dense -> ReLU (with dropout) -> softmax
flat = Flatten()(drop_2)
hidden = Dense(hidden_size, activation='relu')(flat)
drop_3 = Dropout(drop_prob_2)(hidden)
out = Dense(num_classes, activation='softmax')(drop_3)

model = Model(input=inp, output=out) # To define a model, just specify
its input and output layers

model.compile(loss='categorical_crossentropy', # using the cross-entropy
loss function
optimizer='adam', # using the Adam optimiser
metrics=['accuracy']) # reporting the accuracy
```

```
H = model.fit(X_train, Y_train, # Train the model using the training
set...
batch_size=batch_size, nb_epoch=num_epochs,
verbose=1, validation_split=0.1) # ...holding out 10% of the data for
validation
print(model.evaluate(X_test, Y_test, verbose=1)) # Evaluate the trained
model on the test set!

plt.plot(H.history['accuracy'])
plt.plot(H.history['val_accuracy'])
plt.ylabel('Accuracy')
plt.xlabel('Epoch')
plt.legend(['Train', 'Test'], loc='upper left')
plt.show()

plt.plot(H.history['loss'])
plt.plot(H.history['val_loss'])
plt.ylabel('Loss')
plt.xlabel('Epoch')
plt.legend(['Train', 'Test'], loc='upper left')
plt.show()
```